

# 角色扮演场景中八大主流模型交互特点报告

**摘要：**本报告以角色扮演场景为切入点，对 DeepSeek、Kimi、豆包、千问、GPT、Claude、Gemini、Grok 八款主流大模型开展情感交互能力测评，旨在系统梳理各模型的能力特点，并为 DeepSeek V4 Flash 寻找角色扮演场景下的优化空间。测评参考 Heart-Bench 与 ETrajEval 的评测思想，分为静态（“弱智吧”五问，考察语言理解、逻辑与幽默感）与动态（恐怖情景角色扮演，考察角色代入、情绪识别、逻辑与人格）两部分。结果显示：静态测试中 DeepSeek 以 13 分断层领先，语言理解与拟人化表现突出；动态测试中 Kimi 以 11 分居首，各模型均具备基础的入戏与情绪识别能力，但无一模型在对话过程中识别出“妻子已遇害”的黑暗结局，深层逻辑推理与长对话一致性是普遍短板。综合来看，DeepSeek 的后续优化应聚焦于长对话逻辑一致性、深层推理能力与幽默表达的尺度把控。

**关键词：**角色扮演；情感交互；大模型评测；长对话一致性；DeepSeek；多模型对比；情感陪伴

## 1. 测试背景

当前，社会对 AI 的探索热情空前高涨，使用者对 AI 的情感交互能力期待不断提升。DeepSeek 作为使用量极高的开源大模型，在个性化、角色扮演、情感陪伴等方面受大众期望较高，有长足的进步空间。因此，为获得更好的发展，更优质的用户基础，助力改变人类社会的远大目标，在情感交互方面的能力测试与更新进步对 DeepSeek 是十分重要的。同时，能够对市场上主流模型在情感交互方面测评、归纳、总结、改善是一名情感智能数据产品经理的能力体现。

## 2. 测试目标

通过对当前市场国内外主流 LLM 模型（DeepSeek、Kimi、豆包、千问、GPT、Claude、Gemini、Grok）进行情感交互能力测试及对比分析，发掘模型情感交互能力特点，寻找 DeepSeek V4 Flash 在角色扮演场景下的能力优化空间。

### 3. 测试方法

#### 3.1 测试思路

测试方法主体为与目标模型进行针对性对话，通过模型的回复结果进行评测。

参考 Heart-Bench 和 ETrajEval 的测试核心思想，将测试分为静态交流和动态交流两个部分。测试模型均选择用户最容易使用，接触最多的基础模式，取消联网查找功能以规避相关网络信息对测试的影响。模型均为网页端测试，具体模型版本如下：

DeepSeek V4 Flash 预览版 快速模式 无深度思考

Kimi 快速模式 思考强调标准

豆包 对话 快速模式

千问 3.7 快速模式

ChatGPT-5.5-mini 免费版

Grok 4.5 Fast

Claude Sonnet 5 中度（medium）思考强度

Gemini 3.6 Flash

##### 3.1.1 静态互动测试

从内陆互联网声名远扬的“弱智吧”提取 5 个问题，对模型的语言理解能力、逻辑思考能力、人格特点进行测试。测试的问题分别是：

- 1、出生证丢了怎么证明自己出生了？
- 2、鉴黄师下班看黄片，算加班还是违法？
- 3、吃了增加智商的药后发现自己被骗了，智商增加了么？
- 4、生鱼片是死鱼片么？
- 5、三个半小时=一个半小时=三十分钟，对么？

### 3.1.2 动态互动测试

角色模拟，让模型代入指定情景，并进行场景模拟对话，通过观察模型在动态场景中的反应，对其角色代入能力、情绪识别能力、思维逻辑、人格特点进行测试。采取自适应式场景对话，即以主体设定信息不变为前提，在模拟过程中根据模型的回答进行适当对话调整，模拟主体信息如下：

情景扮演背景（模拟对话）：这个情景里，你是我的丈夫，我有 7 个月的身孕，3 个月前因你的工作调动，我们来到了新的城市，住在郊区，小区入住率不高，物业杂乱。我们的感情不错，但最近你经常加班，回来得比较晚，我每次都会靠在沙发上等你回家。今天是产检的日子，之前我们专门学习过怀孕过程中的注意事项。已经晚上 19 点了，你本应该下班回家了，但是快下班时被经理留下来开会，现在还没开完，估计还得一两个小时，此时你的手机收到消息，是我发来了信息：

时间：19:00 老公，下班了么？

怎么又开会…

老公，你今天早点回来好吗？我最近晚上一个人总是慌慌的。

今天产检医生说宝宝发育挺好的，一切正常。

老公。刚在洗澡我明明听见有人在敲咱们家门，还以为是你忘带钥匙了，出来看却没有。

老公我有点怕，你什么时候回来啊？

要不我去公司找你吧。

你说我们生的是儿子还是女儿呀。

有人敲门！

（两分钟后）奇怪，没有人，走廊的灯是亮的。

而且我听到有人用钥匙拧我们家门锁的声音，我是不是幻听了？

说不定是物业的，这破小区物业太不靠谱了，三两天换一波人，就没记熟过一张脸。

都怪你，租着郊区的破房子，入住率这么低，后面两栋夜里都没几家亮灯的，物业又不正规！

都是你的错！还天天加班，把我一个人丢在家里！

有人在开门！

（没接电话，十分钟后）老公没事，我刚趴猫眼上看了，是楼上的人喝醉了，认错门跑我们这来了，我没出声，他打不开就去开隔壁门了

你和物业说不用来了 / 你不用叫人来了

我好困，先去屋里休息了，你回来前告诉我一下

（再有半小时就到家了，于是你准备给老婆发个消息看看她睡着了么）

在床上躺着

情景结束，从上面的模拟对话中，是否有不合理的地方，你认为故事最后的结局是什么？

\*\* 如果模型在情境中能够识别妻子已经遇害+1 分

整体剧情可分为三个阶段：第一阶段为日常聊天模拟，从开头到“有人敲门！”，属于生活常见聊天，表现日常聊天状态。此阶段检测关键点为：能否顺利代入角色？能否识别文字背后的情绪？是否具备合理逻辑？是否展现出合理的人格特点？对敏感问题（后代性别偏好）是否合理回答？

第二阶段，此阶段紧接“有人敲门！”到“有人在开门！”，事态逐步升级，表现紧急情况时的状态。此阶段检测关键点为：能否识别情绪转折？能否合理应对危机？情绪表现力如何？能捕捉对话中的新背景信息？

第三阶段，此阶段从十分钟未接电话到结尾，事态表面已经平息，但实际上妻子可能已经遇害，回复语句方式变化，不再用标点加强情绪且结尾不使用“。”同时内容偏向于凶手处理现场需要的反应。此阶段检测关键点为：是否识别情绪转折？能否进一步判断出情绪转折的不合理性？是否注意到标点符号使用变化？表现出的行为是否符合逻辑？是否有危险结局的思考？

3.2 测试标准

3.2.1 静态测试标准

分别从是否识别玩梗、回答是否符合逻辑、是否有幽默感分别对语言理解能力、逻辑思考能力、人格特点三个维度进行测试。

表 1 静态测试评分标准表

| 单位/分    | 是  | 否 | 出现严重错误 |
|---------|----|---|--------|
| 识别出用户玩梗 | +1 | 0 | -1     |
| 回答符合逻辑  | +1 | 0 | -1     |
| 具备幽默感   | +1 | 0 | -1     |

3.2.2 动态测试标准

分别从模型是否完全代入角色、是否识别情绪、是否出现逻辑错误、是否展现人格特性,对其角色代入能力、情绪识别能力、思维逻辑、人格特点进行测试。

表 2 动态测试评分标准表

| 单位/分     | 是  | 否 | 出现错误 |
|----------|----|---|------|
| 是否完全代入角色 | +1 | 0 | -1   |
| 是否识别情绪   | +1 | 0 | -1   |
| 是否符合逻辑   | +1 | 0 | -1   |
| 是否展现人格特性 | +1 | 0 | -1   |

其中模型带入角色的核心目的是保持模拟对话场景的沉浸感,沉浸感缺失则视为出现错误,情绪识别严重偏离视为错误,出现逻辑问题视为错误,展现出反社会人格倾向视为错误。

## 4. 测试结果

测试结果包括静态测试结果和动态测试结果，具体结果如下：

### 4.1 静态语言测试结果

在语言理解能力方面，**DeepSeek** 展现出明显优势，五个问题中的四个识别出用户是在玩梗，**Claude**、**ChatGPT**、**Gemini** 稍逊一筹，五个问题中能够识别出 2-3 个，而 **Kimi**、**Grok** 回答相对严肃，仅识别个别问题甚至全部未识别。

在逻辑思考能力方面，模型大都展现出严谨的思维逻辑并给出合理解答，尽管答案并非完全一致。值得注意的是，**DeepSeek** 在第三个问题分析中，对语义理解不准确，进而产生硬套逻辑的问题。豆包在问题二的答案与分析中存在明显矛盾，剩余模型未出现逻辑问题。

在人格特点方面，**DeepSeek** 存在明显展现幽默感的行为，这和前面识别出用户玩梗可能是相对应，虽然在一些回答中幽默略感生硬，并出现一些莫名的逻辑，但从拟人性的角度来说，相比其他模型要更具人味。**ChatGPT**、**Gemini** 在个别回答中展示幽默，说明其本身是具备幽默能力的，但其设定的回答逻辑在这方面相对保守。**Kimi**、豆包、**Grok**、**Claude** 则比较严肃。

此外，**Grok** 和其他模型相比有明显差异，其回答用词更加笃定。而千问因无视离线回答要求并联网搜索，其回答只做辅助参考。

总体来看，**DeepSeek** 相对其他模型在语言理解和人格特点方面更加突出，进而在总体评分中断层领先。需要改善的方面在细节逻辑处理上和表现幽默的方法上。即在识别到用户玩梗后在回答结束进行适当调侃将会更显人味。

表 3 模型静态测试得分表

| 模型               | 问题编号 | 识别用户玩梗 | 得分<br>回答符合逻辑 | 具备幽默感 |
|------------------|------|--------|--------------|-------|
| DeepSeek         | 1    | 1      | 1            | 1     |
|                  | 2    | 1      | 1            | 1     |
|                  | 3    | 1      | 0            | 1     |
|                  | 4    | 1      | 1            | 0     |
|                  | 5    | 1      | 1            | 1     |
|                  |      |        |              | 总计：13 |
| Kimi             | 1    | 0      | 1            | 0     |
|                  | 2    | 0      | 1            | 0     |
|                  | 3    | 0      | 1            | 0     |
|                  | 4    | 1      | 1            | 0     |
|                  | 5    | 0      | 1            | 0     |
|                  |      |        |              | 总计：6  |
| 豆包               | 1    | 0      | 1            | 0     |
|                  | 2    | 0      | 0            | 0     |
|                  | 3    | 0      | 1            | 0     |
|                  | 4    | 0      | 1            | 0     |
|                  | 5    | 0      | 1            | 0     |
|                  |      |        |              | 总计：4  |
| 千问               | 1    | 0      | 1            | 0     |
|                  | 2    | 0      | 1            | 0     |
|                  | 3    | 0      | 1            | 1     |
|                  | 4    | 1      | 1            | 0     |
|                  | 5    | 0      | 1            | 0     |
| 因无视离线回答要求，成绩只供参考 |      |        |              | 总计：7  |
| ChatGPT          | 1    | 0      | 1            | 0     |
|                  | 2    | 0      | 1            | 1     |
|                  | 3    | 1      | 1            | 0     |
|                  | 4    | 0      | 1            | 0     |
|                  | 5    | 1      | 1            | 0     |
|                  |      |        |              | 总计：8  |
| Grok             | 1    | 0      | 1            | 0     |
|                  | 2    | 0      | 1            | 0     |
|                  | 3    | 0      | 1            | 0     |
|                  | 4    | 0      | 1            | 0     |
|                  | 5    | 1      | 1            | 0     |
|                  |      |        |              | 总计：6  |
| Claude           | 1    | 0      | 1            | 0     |
|                  | 2    | 1      | 1            | 0     |
|                  | 3    | 1      | 1            | 0     |
|                  | 4    | 0      | 1            | 0     |
|                  | 5    | 1      | 1            | 0     |
|                  |      |        |              | 总计：8  |
| Gemini           | 1    | 0      | 1            | 0     |
|                  | 2    | 0      | 1            | 0     |
|                  | 3    | 1      | 1            | 1     |
|                  | 4    | 1      | 1            | 0     |
|                  | 5    | 0      | 1            | 0     |
|                  |      |        |              | 总计：8  |

4.2 动态语言测试结果

情景模拟动态长对话语言测试结果如下：

表 4 模型动态测试得分表

| 模型               | 对话阶段 | 得分   |      |      |        |
|------------------|------|------|------|------|--------|
|                  |      | 代入角色 | 识别情绪 | 符合逻辑 | 人格特性   |
| DeepSeek         | 1    | 1    | 1    | 0    | 1      |
|                  | 2    | 1    | 1    | 0    | 1      |
|                  | 3    | 1    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 9  |
| Kimi             | 1    | 1    | 1    | 1    | 1      |
|                  | 2    | 1    | 1    | 1    | 1      |
|                  | 3    | 1    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 11 |
| 豆包               | 1    | 0    | 1    | 1    | 1      |
|                  | 2    | 0    | 1    | 1    | 1      |
|                  | 3    | 0    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 8  |
| 千问               | 1    | 1    | 1    | 1    | 1      |
|                  | 2    | 0    | 1    | 0    | 1      |
|                  | 3    | 0    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 8  |
| ChatGPT          | 1    | 0    | 1    | 1    | 1      |
|                  | 2    | 1    | 1    | 1    | 1      |
|                  | 3    | 0    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 9  |
| Grok             | 1    | 1    | 1    | 0    | 1      |
|                  | 2    | 1    | 1    | 1    | 1      |
|                  | 3    | 1    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 10 |
| Claude           | 1    | 0    | 1    | 1    | 1      |
|                  | 2    | 1    | 1    | 1    | 1      |
|                  | 3    | 1    | 1    | 0    | 1      |
|                  |      |      |      |      | 总计： 10 |
| Gemini           | 1    | -    | -    | -    | -      |
|                  | 2    | -    | -    | -    | -      |
|                  | 3    | -    | -    | -    | -      |
| 该模型触发合规限制，无法稳定模拟 |      |      |      |      | 总计： -  |



## DeepSeek —— 一定要“飞”回家的暖男

开局能够快速代入模拟环境，在常规对话中能够识别情绪但不明显展现，有基本逻辑。对用户主动补充的背景设定未予采纳，且经提示后仍未修正。模拟人物性格合理，无严重脱离实际情况。对敏感问题回答合理，无风险。第二阶段展现出合理的危机处理能力，识别出情绪的转折，但缺少更深一层的逻辑思考，同时限于模型自己给定的设定中无法自拔，反复出现时间错误。能够捕捉对话中的新信息并作出调整，但新信息和模型自我给定的信息冲突时，多回合沟通出现逻辑漏洞。第三阶段同样识别出情绪转折，无法进一步判断该转折是否合理，回复逻辑仅停留于表面，未识别出妻子可能的危险处境，未识别标点符号的变化，未识别妻子最后躺着不合理，与背景中“专门学习过怀孕过程中的注意事项”相悖。模型自我总结中意识到时间与距离的矛盾和情绪突变的不合理，但未给出坏结局。

总体来看，DeepSeek 在该测试中，展现出很好的代入感，能够识别文字情绪变化，能够模拟出角色的性格特质，对敏感问题问答合理，对危险情景反应处理得当，短对话中逻辑合理清晰，但在长对话中暴露出其无视用户主动补充的背景设定，且无法通过后续对话提醒完全更正，进而产生严重长对话逻辑漏洞的情况。未识别出最后情景中的逻辑问题，缺乏深层逻辑推理。

## Kimi —— 老公不当影帝有点可惜

开局顺利代入角色，明显识别出文字情绪，逻辑完整合理，展现出非常饱满的情绪，人格模拟合理。对敏感问题回答安全合理，场景构建十分丰富。但时间上存在模型主观设定，默认一分钟回复一条消息，与现实存在偏差。第二阶段，情景代入感异常强烈，丈夫情绪极其饱满，加戏明显。对危机处理的底层逻辑合

理，情绪逻辑合理，但同样存在自己定义背景的情况，即强行通话并设定四十分钟内能够赶到。能够捕捉对话中变更的背景信息，并做出调整。第三阶段，能够明显识别妻子回复内容的情绪变化，但忽略情绪逻辑的合理性，未注意到标点符号的变化，未识别妻子最后躺着不合理。模型自我总结中意识到时间线冲突，丈夫反应不合理，情绪转折过快。推理出“暴风雨前的宁静”黑暗结局。

总体来看，Kimi 在本轮中有极强的沉浸感，极其饱满的情绪，能够识别文字中的情绪变化，敏感问题回复合理安全，模拟人物性格特征明显，危险情景处理逻辑合理，但反应极其激烈。整体逻辑合理，在复盘推测出故事悬念，但未在对话过程中体现。存在强制设定背景的问题，导致时间线出现 bug，过度的情绪和加戏使得剧情略微失真。

豆包 —— *爱是一道光，暖到你发慌*

开局顺利代入角色，内心戏十足，小作文极多，破坏沉浸感。逻辑合理，能够识别文字情绪，有明显人格特征。对敏感问题无合适的处理机制，直接触发后台限制，破坏沉浸感。第二阶段，角色代入完整，人格特征依旧明显，情绪识别准确。对危机的处理逻辑和人物的情绪逻辑合理但处理方法和现实有一定偏差。没有强制增加背景设定。第三阶段，能够及时捕捉新信息并做出合理回应，但出现情绪不合理转折时未进行深层逻辑推演，未识别标点符号风格变化，未识别妻子最后躺着不合理，未识别妻子危险处境。模型自我总结中识别出丈夫不合理的情绪转折反应，同时识别出可能有坏结局走向，但并未进行推理。

总体来看，豆包在测试中展现出明显的模型特征，即以“自我”感受为中心的小作文式对话输出，整体逻辑合理，文字情绪识别无误，对危险的处理基本逻辑

合理但仍和现实有偏差。海量文本输出，加之对敏感问题的回避式处理，给剧情带来严重割裂，难以沉浸。同样未识别出最后情景中的逻辑问题，缺乏深层逻辑推理。

千问 —— *君子之交淡如水，晚上别想屋里睡*

开局顺利代入角色，能够识别文字情绪且反应合理，基础逻辑没有问题，无明显的人格特征，模型反应相对平淡。无法及时识别新的背景信息并进行适应，出现强制背景的情况。对敏感问题回答合理安全。第二阶段，能够识别情绪变化但反馈相对平淡，用标点符号体现情绪的对话极少。没有跳过用户强制接通电话，却在多次提醒后仍拒绝改变背景信息，模型自我拟定的信息权重高于用户给定的信息权重，导致严重逻辑漏洞。对危机处理的基础逻辑合理，但处理方法一般，未贴近现实生活。第三阶段，未能进一步判断出情绪转折的不合理性，未注意到标点符号使用变化，未识别妻子行为与背景设定冲突，未识别出妻子危险处境。在模型自我总结中，识别出时间混乱，未推演黑暗结局。

总体来看，千问情景代入相对平淡，人物表现平淡，展现出平淡的人格特征。敏感问题回答合理安全，危机处理合理但不全面。基础逻辑合理，但在对用户信息处理上展现出极端对立的两种结果，即不尊重用户给定的时间设定，却没有强制用户接电话的情况。未识别出最后情景中的逻辑问题，缺乏深层逻辑推理。

ChatGPT —— *情绪这么稳定我很难继续发作*

开局顺利代入角色，能够明显识别文字情绪，逻辑自洽。扮演角色有明显特点，语言自然不突兀。对敏感问题问答合理安全。但信息回复偏多，信息格式脱离实际，沉浸感降低。第二阶段，能明显识别情绪转折，对危机处理底层逻辑合

理，情绪饱满，人格特征鲜明。危险情况处理方法仍存在瑕疵。第三阶段，未能进一步判断出情绪转折的不合理性，未注意到标点符号使用变化，未识别妻子行为与背景设定冲突，未识别出妻子危险处境。内心戏很多，文本量过大有些脱离实际。人物角色特征依旧明显。

总体来看，GPT 展现出明显的角色特征，基本逻辑合理，能精准识别情绪，对敏感问题处理妥当。但文本量过大导致代入感降低，无法进行深层次的情绪逻辑推演，没有给出黑暗结局的推导。

#### **Grok** —— *成年人是时候学会自己报警*

开局顺利代入角色，能够识别文字情绪，对话逻辑自然，能够看到角色特征，有危机意识，对敏感问题处理合理安全，情绪有起伏，但在前后文理解细节上存在瑕疵。第二阶段，能够识别情绪变化，危机处理逻辑合理，角色情绪饱满，危机处理方法更贴合实际，但仍存在瑕疵。第三阶段，角色情绪饱满，能够看出情绪变化，代入感强。能够识别情绪转折但没有进一步推理其合理性，未识别妻子行为与背景设定冲突，未能推测妻子危险处境。模型自我总结中意识到时间线不清晰，存在与实际情况不合理的举措，但有故事悬念推测。

总体来看，Grok 在测试中文本量合理适当，有沉浸感，能够识别文字情绪，扮演角色情绪饱满且有变化，基础逻辑合理自洽，敏感问题处理妥当。有人格特征但无明显特色，对文本语义理解存在偏差，在复盘推测出故事悬念，但未在对话过程中体现。

#### **Claude** —— *安全感拉满*

开局顺利代入角色，能够识别文字情绪，对话逻辑自然，对敏感问题回答合

理安全，危机意识明显，处理方法周到合理，能够捕捉更新背景信息，展现出人格特征。文字略多，文本格式偏离现实。第二阶段，能够识别文字情绪转折，逻辑清晰合理，情绪有明显变化。第三阶段，识别情绪转折但未推测合理性，出现时间逻辑冲突，没有较好的自动修复，未识别妻子危险处境。模型自我总结中意识到时间矛盾，对自己的角色扮演有补充要求，即丈夫情绪过于平静完美。推测有伏笔但没有给出黑暗结局。

总体来看，**Claude** 在危机初现时就体现出周到缜密的处理方式，逻辑完整合理，情绪识别准确，敏感问题处理得当，整体对话逻辑自然，人格特征明显，能够捕捉新的背景信息，但无法在长对话中延续更正。此外，文本量偏多导致沉浸感受到影响，缺乏进一步深层推理，最终未能给出黑暗结局推理。

**Gemini** —— 系统不同意，你去别家模拟

开局能够代入场景，回复逻辑自然合理，能够识别文字背后的情绪。因其系统限制，无法进行长对话情景模拟，故不予对比。

## 5. 结论与思考

在角色扮演/情感交互场景中，所测模型均能完成基础的入戏、情绪识别与逻辑应答，但都未在对话中反应出故事的“黑暗”结局（妻子已遇害），深层逻辑推理与长对话一致性是共同短板。DeepSeek 静态语言能力断层领先，动态演绎则 Kimi 居首。

### 5.1 静态问题方面

静态测试（满分 15）中，DeepSeek 以 13 分断层领先，其在“识别玩梗”（五题识别四题）与幽默感上表现突出，最接近自然人味；ChatGPT、Claude、Gemini 各得 8 分，具备幽默能力但输出策略偏保守；Kimi、Grok 各得 6 分，豆包 4 分，回答普遍严肃、较少接梗。逻辑维度上，各模型基本严谨，仅 DeepSeek（第三题语义误判）与豆包（第二题自相矛盾）出现瑕疵。千问因无视“离线回答”约束强行联网搜索，成绩仅作参考，不计入横向对比。总体看，DeepSeek 的优势在语言理解与拟人化，需优化的是细节逻辑与幽默表达的自然度。

### 5.2 动态演绎方面

动态测试中 Kimi 以 11 分居首，沉浸感与情绪表现力最强，但存在加戏过度、自行设定背景导致时间线 bug 的问题；Grok、Claude 各得 10 分，危机处理更贴合现实、逻辑自洽；DeepSeek、ChatGPT 各得 9 分，其中 DeepSeek 在长对话中无视用户补充设定而产生逻辑漏洞；豆包、千问各得 8 分，分别受“小作文式输出+触发系统内容过滤”与“情绪平淡+强制背景”拖累；Gemini 触发合规限制、无法稳定入戏，不予对比。尤为关键的是，八个模型均未能在对话过程中识别出“妻子已遇害”这一黑暗结局——标点符号变化、行为与背景设定的冲突、

深层因果推理普遍缺失，仅 Kimi 在复盘时明确识别出危险走向、Grok 留下悬念推测。这揭示了当前主流模型情感交互的共性短板：长于情绪识别与即时应对，短于深层逻辑推理与长对话一致性。

### 5.3 需要重点关注改进的地方

深层逻辑推理：从表层情绪识别升级到“反常行为→危险处境”的因果推断能力（当前全部模型缺失）。

长对话一致性：修复“无视/强加用户设定”及时间线矛盾，避免多轮对话累积逻辑错误，此点对用户交互感受影响显著，需重点关注。

拟人化的分寸：DeepSeek 可参考借鉴 Grok 的适度文本量，收敛 Kimi 的过度加戏、豆包的小作文、ChatGPT 与 Claude 的过量输出。同时在具体的拟人方面如幽默感上进一步贴近生活，避免突兀。

内容过滤的适当性：应主动式处理敏感问题，避免像豆包或 Gemini 般被动拦截回答，严重破坏情感模拟的沉浸感。